

PIPELINE REPRODUCIBLE

Sistema de Recomendacion de Productos

Arquitectura hibrida de Machine Learning sobre el dataset Instacart

EQUIPO

Data Horizon

INTEGRANTES

Augusto Fernandez

Carolina Ponce

Yael Authier

github.com/Caromponce/ProyectoFinal-DataScience-Henry


1. Objetivo y alcance del pipeline

Este documento resume el flujo reproducible del proyecto final: un sistema hibrido de recomendacion de productos sobre el dataset publico Instacart Market Basket Analysis. El pipeline cubre desde la ingesta de datos crudos hasta el despliegue de la API y la interfaz web.

2. Flujo end-to-end

11. Ingesta de datos.
Descarga de los CSV de Instacart y carga en data/.
22. Analisis exploratorio (EDA).
Notebooks con distribucion de compras, sparsity, tasa de recompra y long-tail.
33. Feature engineering.
Construccion de matrices y variables de comportamiento.
44. Segmentacion de usuarios.
K-Means + reglas de negocio para determinar el perfil del usuario.
55. Modelos de recomendacion.
Popularity, Item-Item CF, Market Basket y Reorder Prediction.
66. Backend y frontend.
FastAPI expone la logica; Streamlit consume la API.
77. Deploy.
Docker y Render para ejecucion y demostracion.

Arquitectura funcional



3. Arquitectura de decision (segmentacion -> estrategia)

Segmento de usuario	Estrategia aplicada	Objetivo
Nuevo / sin historial	Popularity Baseline	Resolver Cold Start
Cliente ocasional	Item-Item CF	Similitud de compras pasadas
Cliente leal	Reorder Prediction	Probabilidad de recompra
Todos (transversal)	Market Basket Analysis	Cross-selling complementario

Nota: por limitaciones de memoria del plan gratuito de Render, Reorder Prediction puede operar con fallback de predicciones precalculadas en produccion. El entrenamiento, evaluacion y validacion completos forman parte del pipeline reproducible.

4. Como reproducir el pipeline localmente

Pasos base para clonar el repositorio, instalar dependencias, descargar los modelos entrenados y levantar la API y la interfaz web en un entorno local:

```
git clone https://github.com/Caromponce/ProyectoFinal-DataScience-Henry.git
cd ProyectoFinal-DataScience-Henry
pip install -r requirements.txt
python download_models.py
bash start.sh

# Alternativa con Docker:
docker compose up --build
```

5. Stack tecnologico

Capa	Herramientas
Datos y analisis	Python, Pandas, NumPy
Machine Learning	Scikit-Learn, XGBoost, LightGBM, CatBoost, mlxtend
Backend	FastAPI, Uvicorn
Frontend	Streamlit
DevOps / Deploy	Docker, Render, GitHub, Google Drive

6. Estructura del repositorio

```
ProyectoFinal-DataScience-Henry/
api/          # Endpoints FastAPI
app/          # Interfaz Streamlit
assets/       # Recursos estaticos
data/        # Datasets Instacart
models/      # Modelos entrenados
notebooks/   # EDA y experimentacion
src/         # Logica de modelos
tests/       # Pruebas automatizadas
Dockerfile | docker-compose.yml
download_models.py | start.sh
```

7. Endpoints principales

Metodo	Endpoint	Descripcion
GET	/	Estado del servicio
GET	/health	Health check
GET	/segment/{user_id}	Segmento del usuario
GET	/metrics	Metricas del sistema
POST	/recommend	Generar recomendaciones

8. Validacion, despliegue y cierre

Validacion	Criterio esperado
API	Swagger disponible en /docs y health check activo.
Frontend	Streamlit accesible y conectado al backend.
Recomendacion	POST /recommend devuelve recomendaciones segun el segmento.
Modelos	Los artefactos .joblib se descargan y cargan en runtime.
Deploy	Demo publica disponible en Render.

Demo en vivo y repositorio

Render	proyectofinal-datascience-henry.onrender.com
Repositorio	github.com/Caromponce/ProyectoFinal-DataScience-Henry
Equipo	Data Horizon - Henry Data Science

Conclusion

El pipeline reproducible permite ejecutar el sistema completo siguiendo una secuencia clara: obtener los datos y modelos, levantar los servicios y validar el flujo de recomendacion. La separacion entre Streamlit y FastAPI facilita el mantenimiento, mientras que Docker y Render aportan consistencia entre desarrollo local y despliegue.

Pipeline reproducible listo para demostracion

Data Horizon - Proyecto Final Henry